

FIAP

TECH CHALLENGE – FASE 4

Monitoramento Multimodal de Pacientes com Inteligência Artificial

Análise de vídeo, áudio e sinais vitais com fusão de risco

Aluno	Fernando Monin
Curso	Pós-Tech – Inteligência Artificial para Developers
Instituição	FIAP
Repositório	https://github.com/fmonin/tech-fase4-hospital-monitor-ia-final.git
Vídeo	https://youtu.be/jAP4AR2HWc0

Fernando Monin – rm369303

Pós-graduação em Inteligência Artificial para Desenvolvedores

São Paulo – 2026

Sumário

1. Resumo executivo
2. Contexto e problema
3. Objetivos
4. Visão geral da solução
5. Arquitetura e fluxo de execução
6. Soluções implementadas por modalidade
7. Modelos utilizados
8. Processo de treinamento
9. Resultados e avaliação
10. Pontos importantes da solução
11. Pontos críticos, limitações e riscos
12. Testes e qualidade
13. Como executar o projeto
- 14. Conclusão**
- 15. Referências**

1. Resumo executivo

Este trabalho apresenta um protótipo de monitoramento hospitalar baseado em inteligência artificial capaz de analisar, de forma integrada, três fontes de informação: vídeo, áudio e sinais vitais. A ideia principal foi construir uma solução que não dependesse de apenas um dado isolado para identificar uma situação de risco. Em vez disso, cada modalidade é processada por um módulo específico e, ao final, as evidências são combinadas em uma pontuação única.

O projeto foi desenvolvido em Python e possui uma interface em Streamlit para facilitar os testes. Na parte de vídeo, são avaliados postura, movimento e presença de objetos ou pessoas. No áudio, o sistema realiza transcrição, análise de sentimento, identificação de termos críticos, eventos sonoros e características acústicas. Nos sinais vitais, são observadas frequência cardíaca, saturação de oxigênio e pressão arterial. O resultado é apresentado por meio de alertas e relatórios em JSON e Markdown.

Resultado da entrega — Foi criado um pipeline funcional de ponta a ponta, com modelos treinados, testes automatizados, amostras de demonstração, execução local, suporte a Docker e possibilidade de integração com serviços de nuvem.

2. Contexto e problema

Em um ambiente hospitalar, uma alteração importante pode aparecer primeiro no comportamento do paciente, na forma de falar ou nos sinais fisiológicos. Quando essas informações ficam separadas, existe o risco de um evento relevante ser percebido tarde demais. O desafio foi, propor uma arquitetura de IA que reunisse essas evidências e ajudasse a priorizar situações que merecem atenção.

A solução não pretende substituir médicos, enfermeiros ou fisioterapeutas. Ela funciona como apoio ao monitoramento, destacando padrões fora do esperado e organizando as informações para facilitar a avaliação humana. Esse limite foi considerado desde o início, porque um protótipo acadêmico não possui validação clínica suficiente para tomar decisões autônomas.

3. Objetivos

3.1 Objetivo geral

Desenvolver uma solução multimodal de inteligência artificial para analisar vídeos, áudios e sinais vitais de pacientes, detectar possíveis anomalias e gerar uma visão consolidada do risco.

3.2 Objetivos específicos

- Extrair informações posturais de vídeos e detectar movimentos fora do padrão.
- Identificar pessoas e objetos presentes na cena por visão computacional.
- Transcrever áudios em português e avaliar sentimento, termos críticos e eventos sonoros.
- Analisar séries temporais de frequência cardíaca, SpO₂ e pressão arterial.
- Treinar e persistir modelos de classificação e detecção de anomalias.
- Combinar os resultados em uma fusão multimodal com pontuação de risco.
- Exibir os resultados em uma interface simples e gerar relatórios rastreáveis.

- Manter fallbacks para que a demonstração continue funcionando sem credenciais externas.

4. Visão geral da solução

A solução foi dividida em módulos independentes. Essa separação tornou o desenvolvimento mais organizado e permitiu testar cada parte sem depender da execução completa. O ponto central é a fusão tardia, também chamada de late fusion: vídeo, áudio e sinais vitais são analisados separadamente e somente depois seus resultados são combinados.

Essa escolha foi adequada ao problema porque os tipos de dados são muito diferentes. Vídeo trabalha com imagens e pontos corporais; áudio envolve ondas sonoras, texto e eventos acústicos; sinais vitais são séries numéricas ao longo do tempo. Um único modelo para tudo exigiria uma base grande, alinhada e rotulada, o que não estava disponível para o projeto.

5. Arquitetura e fluxo de execução

Fluxo de execução do monitoramento multimodal




Figura 1 – Fluxo de execução do monitoramento multimodal.

5.1 Passo a passo do processamento

1. O usuário informa os dados do atendimento e seleciona os arquivos ou a fonte de dados.
2. O módulo de vídeo extrai os pontos de pose, calcula atributos posturais e executa a detecção de objetos.
3. O módulo de áudio tenta transcrever a fala, extrai sentimento e termos importantes e avalia eventos sonoros e características acústicas.
4. O módulo de sinais vitais carrega dados sintéticos, CSV ou fonte real opcional e procura violações clínicas e padrões estatísticos anormais.
5. Cada módulo devolve sua pontuação, severidade, motivos e evidências.
6. A fusão multimodal aplica pesos e calcula o risco geral do atendimento.

7. O gerenciador de alertas organiza as ocorrências por prioridade.
8. O sistema apresenta o resultado no Streamlit e grava relatórios em JSON e Markdown.

6. Soluções implementadas por modalidade

6.1 Análise de vídeo

O processamento de vídeo utiliza o MediaPipe Pose para localizar 33 pontos do corpo em cada quadro. A partir desses pontos, o projeto calcula características mais fáceis de interpretar, como assimetria dos ombros e quadris, inclinação do tronco, ângulos de joelhos e cotovelos e velocidade do movimento. Essa estratégia foi escolhida para aproximar as saídas do que um profissional observaria em uma avaliação postural.

- MediaPipe Pose para extração do esqueleto corporal.
- YOLOv8n pré-treinado no conjunto COCO para detectar pessoas e objetos.
- Random Forest para classificar janelas de movimento como normais ou anômalas.
- Regras explicáveis como fallback quando o arquivo do modelo não estiver disponível.
- Geração de vídeo anotado com esqueleto, caixas de detecção e marcação dos frames anômalos.

6.2 Análise de áudio

No áudio, foram combinadas técnicas de fala, processamento de linguagem natural e classificação de sons. A transcrição pode ser realizada pelo **Azure Speech to Text**. O texto obtido é enviado ao **Azure Text Analytics** para análise de sentimento e extração de frases-chave. Em paralelo, o YAMNet identifica eventos como tosse, engasgo, gemido ou respiração alterada. Também são extraídas características acústicas com a biblioteca librosa.

- Transcrição de consultas em português.
- Análise de sentimento e identificação de termos clínicos de atenção.
- Extração de pitch, silêncio e energia para avaliar indícios de alteração vocal.
- YAMNet pré-treinado no AudioSet para reconhecimento de eventos sonoros.
- Funcionamento parcial quando Azure ou TensorFlow não estão configurados.

6.3 Análise de sinais vitais

Os sinais vitais analisados são frequência cardíaca, SpO₂, pressão sistólica e pressão diastólica. O módulo combina limites clínicos explícitos com um modelo treinado. As regras são importantes porque explicam diretamente por que um valor foi sinalizado, enquanto o modelo ajuda a reconhecer combinações e variações que não seriam percebidas por um único limite.

- Entrada por dados sintéticos, CSV próprio ou fontes reais opcionais.
- Random Forest treinado com janelas de 15 minutos.
- Cálculo de média, desvio-padrão, mínimo e máximo de cada sinal.
- Agrupamento de pontos consecutivos em episódios para evitar excesso de alertas.
- Isolation Forest como alternativa não supervisionada para dados reais.

6.4 Fusão multimodal e relatórios

A fusão recebe os resultados de todos os módulos e transforma as diferentes evidências em uma pontuação comum. Eventos mais graves recebem peso maior. Além do risco geral, o relatório informa qual modalidade

contribuiu mais, os principais motivos do alerta e a severidade de cada ocorrência. Essa rastreabilidade foi considerada essencial para que a saída não fosse apenas uma classificação sem explicação.

7. Modelos utilizados

Área	Modelo/Técnica	Tipo	Entrada principal	Finalidade
Vídeo	MediaPipe Pose	Modelo pré-treinado	Frames de vídeo	Extrair 33 pontos corporais
Vídeo	YOLOv8n	Deep learning pré-treinado	Frames de vídeo	Detectar pessoas e objetos
Movimento	Random Forest	Supervisionado	16 features de postura	Classificar normal/anômalo
Áudio	Azure Speech to Text	Serviço cognitivo	Arquivo de áudio	Transcrever fala
Texto	Azure Text Analytics	NLP em nuvem	Transcrição	Sentimento e termos-chave
Eventos sonoros	YAMNet	Rede pré-treinada	Forma de onda	Reconhecer classes de som
Voz	Random Forest	Supervisionado	Pitch, silêncio e energia	Identificar alteração vocal
Sinais vitais	Random Forest	Supervisionado	16 features estatísticas	Classificar janelas clínicas
Dados reais	Isolation Forest	Não supervisionado	Padrões normais	Detectar desvios sem rótulos
Relatório	OpenAI opcional	Modelo generativo	Resultado estruturado	Gerar resumo textual

8. Processo de treinamento

Os modelos supervisionados seguem um processo semelhante. Primeiro são construídos exemplos rotulados como normal ou anômalo. Depois é realizada a separação estratificada de 80% para treinamento e 20% para teste. O algoritmo usado é o RandomForestClassifier, configurado com 200 árvores e profundidade limitada. Ao final, o modelo é salvo em arquivo. joblib e as métricas são armazenadas em JSON.

8.1 Modelo de sinais vitais

Foram geradas 1.000 janelas de 15 minutos. Metade representa comportamento normal e metade recebe uma anomalia injetada, como dessaturação, taquicardia, hipotensão ou hipertensão. Cada janela é transformada em 16 atributos: média, desvio-padrão, mínimo e máximo dos quatro sinais.

8.2 Modelo de movimento

O conjunto também possui 1.000 janelas, cada uma com 15 frames. As anomalias simuladas incluem assimetria de ombro, assimetria de quadril, inclinação de tronco, joelho travado e movimento brusco. As mesmas features usadas na inferência são utilizadas durante o treino, evitando diferenças entre a preparação dos dados e o uso do modelo.

8.3 Modelo de voz

O treino utiliza 1.000 exemplos simulados no espaço de características acústicas. Vozes consideradas alteradas apresentam, de forma controlada, menor variação de pitch, mais silêncio e menor energia. O objetivo é demonstrar o pipeline de extração, treino, avaliação e inferência.

8.4 Treinamentos alternativos com dados reais

- Isolation Forest sobre frequência cardíaca derivada do MIT-BIH/PhysioNet.
- Isolation Forest treinado com vídeos reais de movimentos considerados normais.
- Random Forest sobre embeddings de 1.024 dimensões extraídos pelo YAMNet de áudios organizados por classe.

Justificativa dos dados sintéticos — O aprendizado supervisionado exige rótulos confiáveis. Como os conjuntos clínicos reais utilizados não trazem marcações completas de anomalia, a injeção controlada foi usada para validar o funcionamento técnico do pipeline. Dados reais foram mantidos como caminho de validação e evolução.

9. Resultados e avaliação

Nos arquivos de métricas presentes no repositório, os três modelos supervisionados alcançaram acurácia, precisão, recall e F1 de 100% no conjunto de teste sintético. Esse resultado confirma que o pipeline de preparação, treino, persistência e inferência está funcionando de forma consistente para os exemplos controlados.

Modelo	Acurácia	Precisão	Recall	F1-score
vitais_rf	100%	100%	100%	100%
movimento_rf	100%	100%	100%	100%
audio_rf	100%	100%	100%	100%

É importante interpretar esses valores com cuidado. As anomalias foram criadas com separação clara entre as classes, o que torna o problema mais simples do que um cenário hospitalar real. Portanto, as métricas não significam que o modelo está clinicamente validado ou que terá o mesmo desempenho diante de ruído, pacientes diferentes, equipamentos diferentes e situações de fronteira.

10. Pontos importantes da solução

Fusão tardia: Permite escolher a técnica mais adequada para cada modalidade e mantém o sistema operando mesmo quando uma entrada não está disponível.

Explicabilidade: Os alertas carregam motivos, valores e modalidade de origem. As features do Random Forest também podem ser inspecionadas.

Modularidade: Vídeo, áudio, sinais vitais, fusão, relatórios e treinamento ficam separados em pacotes próprios.

Resiliência da demonstração: Serviços opcionais possuem fallback; assim, a aplicação continua executando sem Azure, OpenAI, YAMNet ou fonte real.

Reprodutibilidade: Os modelos já treinados, métricas, amostras e comandos de execução ficam versionados no repositório.

Interface visual: O Streamlit organiza o cadastro do atendimento, análises individuais, treinamento e relatório geral.

Rastreabilidade: As execuções produzem relatórios JSON e Markdown, facilitando auditoria e comparação.

Testabilidade: Há testes automatizados para detectores, carregadores, treinamento, fusão e geração de vídeo anotado.

11. Pontos críticos, limitações e riscos

- **Dados sintéticos:** Os modelos padrão aprenderam exemplos artificiais. A evolução mais importante é obter bases reais, anonimizadas e rotuladas por especialistas.
- **Métricas elevadas:** O resultado de 100% ocorre em um cenário controlado e não pode ser tratado como evidência de desempenho clínico.
- **Generalização de vídeo:** Iluminação, posição da câmera, oclusão, roupas, mobilidade reduzida e uso de equipamentos podem prejudicar a pose.
- **Limitações do YOLO:** O modelo COCO reconhece objetos gerais, não instrumentos médicos específicos. Um uso real exigiria fine-tuning.
- **Qualidade do áudio:** Ruído, distância do microfone, sotaque, sobreposição de falas e privacidade podem afetar transcrição e classificação.
- **Dependência de serviços externos:** Azure e OpenAI dependem de internet, credenciais, custo, disponibilidade e regras de tratamento de dados.
- **Privacidade e LGPD:** Vídeo, voz e sinais clínicos são dados sensíveis. Uma implantação real exigiria consentimento, controle de acesso, criptografia, retenção e auditoria.
- **Falsos positivos e negativos:** Alertas em excesso podem causar fadiga; falhas de detecção podem atrasar uma avaliação. Os limiares precisam de calibração clínica.
- **Responsabilidade humana:** O sistema deve ser usado apenas como suporte. A decisão continua sendo do profissional de saúde.
- **Validação prospectiva:** Antes de uso real seriam necessários estudos com pacientes, revisão ética e comparação com protocolos hospitalares.

12. Testes e qualidade

Os testes automatizados são executados com pytest. Eles cobrem partes essenciais para reduzir regressões durante alterações no código. Entre os cenários estão carregamento de CSV, detectores de anomalia, modelos de treinamento, fusão multimodal, consistência das features e criação de vídeo anotado.

- Executar toda a suíte: `pytest tests/ -v`
- Validar se os modelos são salvos e carregados corretamente.
- Verificar se treino e inferência usam o mesmo conjunto de atributos.
- Testar entradas normais e entradas com anomalias conhecidas.
- Confirmar que componentes opcionais não interrompem a execução principal.

13. Como executar o projeto

13.1 Pré-requisitos

- Python 3.10 ou 3.11
- pip e ambiente virtual
- Docker e Docker Compose, opcionais
- Conta Azure, opcional
- Chave OpenAI, opcional
- Conta Kaggle para o dataset de fisioterapia, opcional

13.2 Instalação local

```
git clone https://github.com/fmonin/tech-fase4-hospital-monitor-ia-final.git
cd tech-fase4-hospital-monitor-ia-final
python -m venv .venv
.venv\Scripts\activate
pip install -r requirements.txt
```

13.3 Interface Streamlit

```
streamlit run frontend/app.py
```

13.4 Execução por linha de comando

```
python -m src.main --demo
python -m src.main --csv amostras/sinais_vitais_exemplo.csv
python -m src.main --demo --video amostras/video_exemplo_com_anomalia.mp4
```

13.5 Treinamento

```
python -m src.training.treinar_tudo
```

14. Conclusão

O desenvolvimento deste Tech Challenge permitiu aplicar conceitos de visão computacional, processamento de áudio, séries temporais, aprendizado supervisionado, aprendizado não supervisionado e integração multimodal em um único projeto. O principal aprendizado foi perceber que a qualidade de uma solução de IA não depende apenas do modelo, mas também da preparação dos dados, da explicação dos resultados, dos fallbacks, dos testes e da forma como o usuário visualiza a informação.

A arquitetura criada atende ao objetivo acadêmico de demonstrar um monitoramento hospitalar inteligente de ponta a ponta. Ao mesmo tempo, o projeto deixa claros os limites entre um protótipo funcional e uma ferramenta clínica. Como próximos passos, seria necessário ampliar os dados reais, realizar rotulagem especializada, calibrar os limiares, treinar o YOLO para objetos hospitalares e validar o sistema com profissionais de saúde em ambiente controlado.

Considero que a fusão multimodal foi a parte mais relevante da entrega, porque ela transforma componentes isolados em uma solução única. Em vez de mostrar apenas uma classificação de vídeo, uma transcrição ou

um gráfico de sinais vitais, o sistema consegue organizar todas essas evidências em uma visão geral do paciente e indicar os motivos que contribuíram para o risco.

15. Referências

- Projeto desenvolvido: <https://github.com/fmonin/tech-fase4-hospital-monitor-ia-final>
- Google MediaPipe – Pose Landmarker: https://ai.google.dev/edge/mediapipe/solutions/vision/pose_landmarker
- Ultralytics YOLO: <https://docs.ultralytics.com>
- Microsoft Azure AI Speech: <https://learn.microsoft.com/azure/ai-services/speech-service/>
- Microsoft Azure AI Language: <https://learn.microsoft.com/azure/ai-services/language-service/>
- YAMNet – TensorFlow Hub: <https://tfhub.dev/google/yamnet/1>
- AudioSet: <https://research.google.com/audioset/>
- scikit-learn – Random Forest e Isolation Forest: <https://scikit-learn.org>
- Streamlit: <https://streamlit.io>
- PhysioNet: <https://physionet.org>